

缘起

近一年来做信号处理，感觉数学公式的推导非常重要。公式只要理解深刻，后续做matlab，跑数据，写c程序，上产品都有了提纲挈领之感。而信号处理中用的最多的自适应滤波器，它的公式推导过程中很多都需要用到复数或复矩阵的求导，我用的信号处理的书默认大家都有了很好的数学基础，这方面写得语焉不详，尤其喜欢在证明中间忽略一两步，看的人非常郁闷。于是最近花了一些业余时间搜集了一些资料好好学习了一下，这篇文章就是学习过程中的一些总结，希望能对信号处理的初学者有所帮助。

复数的求导

解析函数

连续

如果极限 $\lim_{\Delta z \rightarrow 0} f(z_0 + \Delta z) = f(z_0)$ 存在，则说 $f(z)$ 在 z_0 连续。

可导

设函数 $w = f(z)$ 定义于区域 D 。 z_0 是 D 中的一点，点 $z_0 + \Delta z$ 不出 D 的范围。如果极限

$$\lim_{\Delta z \rightarrow 0} \frac{f(z_0 + \Delta z) - f(z_0)}{\Delta z}$$

存在，则认为该函数在 z_0 可导。这个极限值就是 $f(z)$ 在 z_0 处的导数。

注意，这个极限的下标 $\Delta z \rightarrow 0$ 的方式有很多种。 因为 z 是一个复数，我们可以想象它是复平面上的一点，那么它逼近原点的方式是多种多样的。

可导的充要条件

设函数 $f(z) = u(x, y) + iv(x, y)$ 定义在区域 D 内，则 $f(z)$ 在 D 内一点 $z = x + iy$ 可导的充要条件是： $u(x, y)$ 与 $v(x, y)$ 在点 (x, y) 可微，并且满足柯西-黎曼方程：

$$\frac{\partial u}{\partial x} = \frac{\partial v}{\partial y} \quad \frac{\partial u}{\partial y} = -\frac{\partial v}{\partial x}$$

解析

如果函数 $f(z)$ 在 z_0 及 z_0 的邻域内处处可导，那么称 $f(z)$ 在 z_0 解析，如果 $f(z)$ 在区域 D 内每一点解析，则称 $f(z)$ 在 D 内解析，或称 $f(z)$ 是 D 内的一个解析函数，也叫全纯函数或者正则函数。

复变函数教科书里对导数的定义到此为止了。




图1 作者的本科教科书

非解析函数

但是，在信号处理领域，需要求导的函数往往是不解析的。

比如自适应滤波器中的损失函数：

均方误差(MSE)

$$Cost = E[|e(k)|^2]$$

最小二乘(LS)

$$Cost = \frac{1}{k+1} \sum_{i=0}^k |e(k-i)|^2$$

加权最小二乘(WLS)

$$Cost = \sum_{i=0}^k \lambda^i |e(k-i)|^2, \quad \lambda < 1$$

瞬时值(LSV)

$$Cost = |e(k)|^2$$

我们发现，若用复数表示 $e(k)$ ，所有的损失函数都可以表示为 $|e(k)|^2 = zz^*$ 的和的形式。

对于最优化问题，需要对损失函数求导，但从严格的数学角度来看，这个函数是不可导的。证明如下：

$$zz^* = x^2 + y^2$$

则：

$$\frac{\partial u}{\partial x} = 2x$$

$$\frac{\partial v}{\partial x} = 0$$

显然不满足柯西-黎曼方程，因此不可导。

那最优化问题如何求解？

非解析函数的求导

假设 $f(z)$ 解析，则 $f(z)$ 可以展开为 z 的泰勒级数的形式，在这个展开式中没有 z^* 的身影，说明 $f(z)$ 和 z^* 没有任何关系。换句话说，一个解析的复变函数只跟 z 有关，和 z^* 无关。

实际上， $f(z)$ 解析可以等价于 $\frac{\partial f}{\partial z^*} = 0$ 。

那么，不解析的函数就同时依赖于 z 和 z^* 。

可以轻松推出一个事实：**实函数 $f(z)$ 都是不解析的。**

因为它必须同时依赖于 z 和 z^* ，否则它的虚部无法被消掉。因此 $f(z) = zz^*$ 作为一个实函数，也印证了上面用柯西-黎曼方程推导出不解析的结果。

所以，一个不解析的复变函数由于同时跟 z, z^* 以及 x, y 有关，可以写成：

$$f(z) = f(z, z^*), \quad f(z) = f(x, y)$$

这两种形式。根据全微分公式：

$$df = \frac{\partial f}{\partial x} dx + \frac{\partial f}{\partial y} dy$$

因此：

$$\begin{aligned} df &= \frac{\partial f}{\partial x} \frac{dz + dz^*}{2} + \frac{\partial f}{\partial y} \frac{dz - dz^*}{2i} \\ &= \frac{1}{2} \left(\frac{\partial f}{\partial x} - i \frac{\partial f}{\partial y} \right) dz + \frac{1}{2} \left(\frac{\partial f}{\partial x} + i \frac{\partial f}{\partial y} \right) dz^* \end{aligned}$$

而根据全微分公式又同样可得：

$$df = \frac{\partial f}{\partial z} dz + \frac{\partial f}{\partial z^*} dz^*$$

因此：

$$\begin{aligned} \frac{\partial f}{\partial z} &= \frac{1}{2} \left(\frac{\partial f}{\partial x} - i \frac{\partial f}{\partial y} \right) \\ \frac{\partial f}{\partial z^*} &= \frac{1}{2} \left(\frac{\partial f}{\partial x} + i \frac{\partial f}{\partial y} \right) \end{aligned}$$

同样的方式又易得：

$$\begin{aligned} \frac{\partial f}{\partial x} &= \frac{\partial f}{\partial z} + \frac{\partial f}{\partial z^*} \\ \frac{\partial f}{\partial y} &= i \left(\frac{\partial f}{\partial z} - \frac{\partial f}{\partial z^*} \right) \end{aligned}$$

根据上面的公式，得到推论：

$$\frac{\partial z}{\partial z} = 1$$

$$\frac{\partial z^*}{\partial z^*} = 1$$

$$\frac{\partial z}{\partial z^*} = 0$$

$$\frac{\partial z^*}{\partial z} = 0$$

$$\frac{\partial (zz^*)}{\partial z} = z^*$$

$$\frac{\partial (zz^*)}{\partial z^*} = z$$

向量和矩阵的求导

当一个函数有很多变量，需要对多变量求导时，为了简化运算，把变量组成向量或者矩阵，作为一个实体来看待，这就是对向量和矩阵的求导。

可能存在的求导有标量，向量，矩阵分别对各自求导，根据排列组合一共有9种情况，比如“标量对标量的求导，向量对标量的求导”等等。要想详细了解可参考：

https://en.wikipedia.org/wiki/Matrix_calculus

这里我们只看最常用的**标量对矢量的求导**。

假设 $f(x)$ 是一个标量， x 是一个矢量， x 可表示为

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$$

则：

$$\frac{\partial f(x)}{\partial \mathbf{x}} = \begin{bmatrix} \frac{f(x)}{x_1} \\ \frac{f(x)}{x_2} \\ \vdots \\ \frac{f(x)}{x_N} \end{bmatrix}$$

为什么是这样呢？ 答案是全微分公式：

$$df = \frac{f(x)}{x_1}dx_1 + \frac{f(x)}{x_2}dx_2 + \cdots + \frac{f(x)}{x_N}dx_N$$

写成向量的乘法就是：

$$df = \left(\begin{bmatrix} \frac{f(x)}{x_1} \\ \frac{f(x)}{x_2} \\ \vdots \\ \frac{f(x)}{x_N} \end{bmatrix} \right)^T d\mathbf{x}$$

根据这个定义， 易得：

$$\frac{\partial \mathbf{x}^T \mathbf{b}}{\partial \mathbf{x}} = \mathbf{b}$$

$$\frac{\partial \mathbf{b}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{b}$$

复数向量和矩阵求导

标量和向量都可以认为是一种简化的矩阵， 所以一个函数对标量， 向量和矩阵的求导都可以统一写为复数对矩阵求导的形式。

假设函数F的参数是一个Q行， N列的复数矩阵（对于标量， 它就是一个1行1列的矩阵， 对于向量， 它就是一个Q行1列的矩阵）， 则可以认为F是Q*N个复数参数的函数， 而每一个复数又包含x， y或者z， z*两个变量， 因此根据全微分公式：

$$df = \sum_{k=0}^{Q-1} \sum_{l=0}^{N-1} \frac{\partial f}{\partial x_{k,l}} dx_{k,l} + \sum_{k=0}^{Q-1} \sum_{l=0}^{N-1} \frac{\partial f}{\partial y_{k,l}} dy_{k,l}$$

$$= \sum_{k=0}^{Q-1} \sum_{l=0}^{N-1} \frac{\partial f}{\partial z_{k,l}} dz_{k,l} + \sum_{k=0}^{Q-1} \sum_{l=0}^{N-1} \frac{\partial f}{\partial z_{k,l}^*} dz_{k,l}^*$$

所以，复数导数F可以看是矩阵 Z 和矩阵 Z^* 的函数，即 $F(\mathbf{Z}, \mathbf{Z}^*)$ 。

我们回忆一下微分的基本原理，对一个函数 $f(x)$ 微分：

$$f(x + dx) - f(x) = FirstOrder(dx) + HighOrder(dx)$$

FirstOrder指的是一阶的dx，HighOrder指的是高阶的dx，微分的计算通常是扔掉高阶的dx，保留一阶的dx，即：

$$df = FirstOrder(dx)$$

对 $F(\mathbf{Z}, \mathbf{Z}^*)$ 求导是一样的道理：

$$\begin{aligned} & F(Z + dZ, Z^* + dZ^*) - F(Z, Z^*) \\ &= FirstOrder(dZ, dZ^*) + HighOrder(dZ, dZ^*) \\ & dF(Z, Z^*) = FirstOrder(dZ, dZ^*) \end{aligned}$$

由此推导出一些结论：

$$\begin{aligned} d(\mathbf{A}\mathbf{Z}\mathbf{B}) &= \mathbf{A}(d\mathbf{Z})\mathbf{B} \\ d(a\mathbf{Z}) &= ad\mathbf{Z} \\ d\mathbf{Z}_0\mathbf{Z}_1 &= (d\mathbf{Z}_0)\mathbf{Z}_1 + \mathbf{Z}_0d\mathbf{Z}_1 \\ d\mathbf{Z}^{-1} &= -\mathbf{Z}^{-1}(d\mathbf{Z})\mathbf{Z}^{-1} \\ d\mathbf{Z}^* &= (d\mathbf{Z})^* \\ d\mathbf{Z}^H &= (d\mathbf{Z})^H \end{aligned}$$

还有对信号处理非常重要的一些结论，均是标量函数对复向量的求导，为了看起来比较清楚，就不写成矩阵的形式了。

$$\begin{aligned} dF(\mathbf{a}^T \mathbf{z}) &= \mathbf{a} d\mathbf{z} \\ dF(\mathbf{z}^T \mathbf{a}) &= \mathbf{a} d\mathbf{z} \end{aligned}$$

注意 $\mathbf{a}^T \mathbf{z} = \mathbf{z}^T \mathbf{a}$

$$\begin{aligned} dF(\mathbf{a}^T \mathbf{z}^*) &= \mathbf{a} d\mathbf{z}^* \\ dF(\mathbf{z}^H \mathbf{a}) &= \mathbf{a} d\mathbf{z}^* \end{aligned}$$

注意 $\mathbf{a}^T \mathbf{z}^* = \mathbf{z}^H \mathbf{a}$

$$dF(\mathbf{z}^T \mathbf{A} \mathbf{z}) = (\mathbf{A} + \mathbf{A}^T) \mathbf{z} d\mathbf{z}$$

$$dF(\mathbf{z}^H \mathbf{A} \mathbf{z}) = \mathbf{A}^T \mathbf{z}^* d\mathbf{z} + \mathbf{A} \mathbf{z} d\mathbf{z}^*$$

$$dF(\mathbf{z}^H \mathbf{A} \mathbf{z}^*) = (\mathbf{A} + \mathbf{A}^T) \mathbf{z}^* d\mathbf{z}^*$$

如果 \mathbf{A} 是广义平稳过程的相关矩阵，那么它是一个埃尔米特矩阵，即 $\mathbf{A}^H = \mathbf{A}$ ，因此上面三个式子可以写成：

$$dF(\mathbf{z}^T \mathbf{A} \mathbf{z}) = 2\mathbf{A} \mathbf{z} d\mathbf{z}$$

$$dF(\mathbf{z}^H \mathbf{A} \mathbf{z}) = \mathbf{A} \mathbf{z}^* d\mathbf{z} + \mathbf{A} \mathbf{z} d\mathbf{z}^*$$

$$dF(\mathbf{z}^H \mathbf{A} \mathbf{z}^*) = 2\mathbf{A} \mathbf{z}^* d\mathbf{z}^*$$

我们把 $\mathbf{z}^H \mathbf{A} \mathbf{z}$ 称为**二次型**（quadratic form），它的求导在DSP的公式推导中非常重要。

应用

1. 维纳滤波（Wiener Filter）

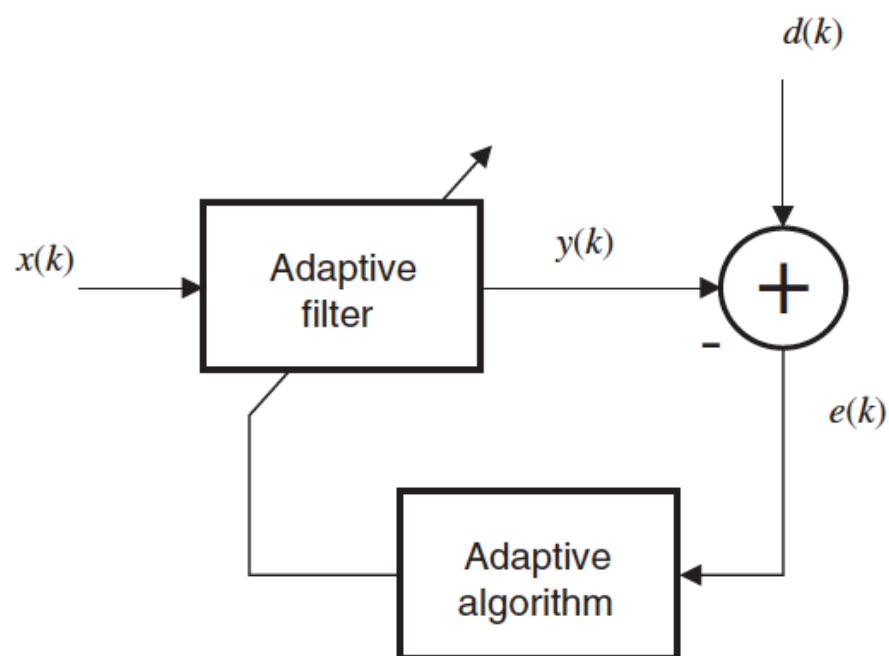


图2 自适应滤波问题

维纳滤波以 $MSE = E(|e(k)|^2)$ 为损失函数。

$$e(k) = d(k) - \mathbf{w}^H \mathbf{x}$$

$$|e(k)|^2 = (d(k) - \mathbf{w}^H \mathbf{x})^H (d(k) - \mathbf{w}^H \mathbf{x})$$

$$= (d^H(k) - \mathbf{x}^H \mathbf{w})(d(k) - \mathbf{w}^H \mathbf{x})$$

$$= |d(k)|^2 - d^H(k) \mathbf{w}^H \mathbf{x} - d(k) \mathbf{x}^H \mathbf{w} + \mathbf{x}^H \mathbf{w} \mathbf{w}^H \mathbf{x}$$

因为 $\mathbf{x}^H \mathbf{w}$ 和 $\mathbf{w}^H \mathbf{x}$ 都是标量，所以：

$$= |d(k)|^2 - d^H(k) \mathbf{w}^H \mathbf{x} - d(k) \mathbf{x}^H \mathbf{w} + \mathbf{w}^H \mathbf{x} \mathbf{x}^H \mathbf{w}$$

根据二次型的求导公式：

$$\frac{\partial |e(k)|^2}{\partial w^*} = -d^H \mathbf{x} + \mathbf{x} \mathbf{x}^H \mathbf{w}$$

加上期望符号E

$$\frac{\partial E(|e(k)|^2)}{\partial w^*} = -E(d^H \mathbf{x}) + E(\mathbf{x} \mathbf{x}^H) \mathbf{w}$$

$$\text{而 } E[\mathbf{x} \mathbf{x}^H] = \mathbf{R}_{xx}$$

$$\text{设 } -E(d^H \mathbf{x}) = \mathbf{P},$$

$$\text{则 } E(|e(k)|^2) \text{ 最小时, } \frac{\partial E(|e(k)|^2)}{\partial w^*} = 0,$$

可得

$$-\mathbf{P} + \mathbf{R} \mathbf{w} = 0$$

$$\mathbf{w} = \mathbf{R}^{-1} \mathbf{P}$$

2. LMS (Least Mean Square)

仍然使用图2中的符号。

MSE这种损失函数实际上是无法求得的，因为求了期望，就要求对信号进行无限次测量。为了能获得维纳解，人们设计了一些方式来进行迭代求解，也就是在维纳的解空间内进行搜索，逐渐逼近维纳解。比如最陡梯度下降法。

意思就是：

$$\mathbf{w}(k+1) = \mathbf{w}(k) - \mu \hat{\mathbf{g}}(k)$$

$\hat{\mathbf{g}}(k)$ 就是第k次迭代的梯度。

我们利用维纳对 $|e(k)|^2$ 求导的结果，可得梯度为 $-d^H \mathbf{x} + \mathbf{x} \mathbf{x}^H \mathbf{w}$

利用最近一次的 $\mathbf{x}(k) \mathbf{x}^H(k)$ 替换掉 $E[\mathbf{x} \mathbf{x}^H]$ ，注意， \mathbf{x} 也是向量。

可得：

$$\mathbf{w}(k+1) = \mathbf{w}(k) - \mu (-d^H(k) \mathbf{x}(k) + \mathbf{x}(k) \mathbf{x}^H(k) \mathbf{w}(k))$$

$$= \mathbf{w}(k) + \mu \mathbf{x}(k)(d^H(k) - \mathbf{x}(k)^H \mathbf{w}(k))$$

注意 $e(k) = d(k) - \mathbf{w}(k)^H \mathbf{x}(k)$ ，两边取共轭转置，可得 $e(k)^H = d^H(k) - \mathbf{x}^H(k) \mathbf{w}(k)$

代入上式，可得 $\mathbf{w}(k+1) = \mathbf{w}(k) - \mu \mathbf{x}(k)e(k)^*$ ，

注意 $e(k)$ 是个标量，共轭转置等于共轭。

3. APA (Affine Projection Algorithm)

仍然使用图2中的符号。

APA是LMS的一种变形。

首先定义

$$\mathbf{e}_{ap}(k) = \mathbf{d}_{ap}(k) - \mathbf{X}_{ap}^T \mathbf{w}^*(k)$$

迭代用的是滤波器系数的共轭，这就意味着我们需要对滤波器系数的共轭求导。其实这也是一个trick，因为对一个复数的共轭求导会得到关于这个复数的方程。

注意，上面的式子全是向量和矩阵，没有标量。

APA依然是一个带约束的最优化问题，

约束条件是后验误差是0，即 $\mathbf{d}_{ap}(k) - \mathbf{X}_{ap}^T(k) \mathbf{w}^*(k+1) = \mathbf{0}$ ， $\mathbf{w}^*(k+1)$ 是更新后的滤波器系数。

最优化目标是使得这个值 $\frac{1}{2} \|\mathbf{w}(k+1) - \mathbf{w}(k)\|^2$ 最小化，这被称为最小距离原理。

采用拉格朗日乘子法：

$$\frac{1}{2}(\mathbf{w}(k+1) - \mathbf{w}(k))^H(\mathbf{w}(k+1) - \mathbf{w}(k)) + \lambda^T(\mathbf{d}_{ap}(k) - \mathbf{X}_{ap}^T(k) \mathbf{w}^*(k+1))$$

注意， λ 是一个实数的列向量，转置是为了相乘后得到一个标量。

上面的式子是一个标量，为了得到关于 $\mathbf{w}(k)$ 的式子，对向量 $\mathbf{w}^*(k+1)$ 求导，求导可得：

$$\frac{1}{2}(\mathbf{w}(k+1) - \mathbf{w}(k)) - (\lambda^T \mathbf{X}_{ap}^T(k))^T$$

最优解是上式为0，则 $\mathbf{w}(k+1) = \mathbf{w}(k) + 2\mathbf{X}_{ap}(k)\lambda$ (3.1)

对约束条件两边取共轭，可得

$$\mathbf{d}_{ap}^*(k) - \mathbf{X}_{ap}^H(k) \mathbf{w}(k+1) = 0$$

把 $\mathbf{w}(k+1) = \mathbf{w}(k) + 2\mathbf{X}_{ap}(k)\lambda$ 代入上式，可得

$$\mathbf{d}_{ap}^*(k) - \mathbf{X}_{ap}^H(k)\mathbf{w}(k) - 2\mathbf{X}_{ap}^H(k)\mathbf{X}_{ap}(k)\lambda = \mathbf{0}$$

$$\mathbf{d}_{ap}^*(k) - \mathbf{X}_{ap}^H(k)\mathbf{w}(k) = 2\mathbf{X}_{ap}^H(k)\mathbf{X}_{ap}(k)\lambda \quad (3.2)$$

由于

$$\mathbf{e}_{ap}(k) = \mathbf{d}_{ap}(k) - \mathbf{X}_{ap}^T \mathbf{w}^*(k)$$

两边取共轭

$$\mathbf{e}_{ap}^*(k) = \mathbf{d}_{ap}^*(k) - \mathbf{X}_{ap}^H \mathbf{w}(k)$$

带入 (3.2)

$$\text{则 } \mathbf{e}_{ap}^*(k) = 2\mathbf{X}_{ap}^H(k)\mathbf{X}_{ap}(k)\lambda$$

$$\lambda = \frac{1}{2}(\mathbf{X}_{ap}^H(k)\mathbf{X}_{ap}(k))^{-1}\mathbf{e}_{ap}^*(k)$$

带入(3.1)

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \mu\mathbf{X}_{ap}(k)(\mathbf{X}_{ap}^H(k)\mathbf{X}_{ap}(k))^{-1}\mathbf{e}_{ap}^*(k)$$

4. LCMV (Linearly Constrained Minimum Variance)




图3 波束形成问题

线性约束最小方差的意思是：在满足约束条件的情况下，让输出信号的功率最小。这个约束条件就是某一方向的信号不衰减。

某方向信号不衰减可以表示为 $\mathbf{w}^H \mathbf{c} = f$ ，推导如下：

整个推导都是在频域，输出是输入信号和滤波器的点乘，假设 $y = \mathbf{w}^* \cdot \mathbf{x}$ 是滤波器的输出，

$$\text{则 } \sum_{i=0}^N y_i = \mathbf{w}^H \mathbf{x} \quad \circ$$

$$x_i(k) = x_0(t_0 + i \frac{d \cos \theta}{c})$$

$$\text{当 } \mathbf{w}^H \mathbf{x} = \mathbf{x}_0$$

$$\mathbf{x}_0 = [x_0 x_0 \cdots x_0]^T$$

$$\text{而 } \mathbf{x} = x_0 \cdot [1, e^{-jw \frac{d \cos \theta}{c}}, e^{-j2w \frac{d \cos \theta}{c}}, \dots, e^{-j(N-1)w \frac{d \cos \theta}{c}}]^T$$

这个可以当做约束条件。

从而又变成了带约束条件的最优化问题，可得式子为：

$$E[\mathbf{w}^H \mathbf{x} \mathbf{x}^H \mathbf{w}] + \lambda(\mathbf{w}^H \mathbf{c} - f)$$

注意， \mathbf{c} 就是 steering vector，而 λ 是一个实数标量。

在约束情况下求最优化问题，还是用拉朗日乘子法。

$$E[\mathbf{w}^H \mathbf{x} \mathbf{x}^H \mathbf{w}] + \lambda(\mathbf{w}^H \mathbf{c} - f)$$

上式对 \mathbf{w}^* 求导，可得：

$$\mathbf{R}_{xx} \mathbf{w} + \lambda \mathbf{c}$$

$$\text{令上式为0，则 } \mathbf{w} = -\lambda \mathbf{R}^{-1} \mathbf{c} \quad (4.1)$$

$$\text{代入 } \mathbf{w}^H \mathbf{c} = f, \text{ 因为是标量，两边取转置不变，这个式子可以写成 } \mathbf{c}^H \mathbf{w} = f, \text{ 代入 (4.1)}$$

$$-\lambda \mathbf{c}^H \mathbf{R}^{-1} \mathbf{c} = f, \text{ 则}$$

$$\lambda = -(\mathbf{c}^H \mathbf{R}^{-1} \mathbf{c})^{-1} f$$

最后代入式子 (4.1)

$$\mathbf{w} = \mathbf{R}^{-1} \mathbf{c} (\mathbf{c}^H \mathbf{R}^{-1} \mathbf{c})^{-1} f$$

5. MVDR (Minimum Variance Distortionless Response)

仍然使用图3中的符号。

输入信号是：

$$\mathbf{x} = \mathbf{s} + \mathbf{i} + \mathbf{n}$$

其中 \mathbf{s} 是纯净语音信号， \mathbf{i} 是干扰信号， \mathbf{n} 是噪音信号。

目标是要求得一个滤波器系数 \mathbf{w} ，在约束条件 $\mathbf{w}^H \mathbf{a} = 1$ 下，使得 SINR（信干噪比）最大。

$$SINR = E\left[\frac{|\mathbf{w}^H \mathbf{s}|^2}{|\mathbf{w}^H (\mathbf{i} + \mathbf{n})|^2}\right]$$

E是求期望。

我们希望分母最小，当然还是选择拉格朗日乘子法：

$$E[\mathbf{w}^H \mathbf{R}_{i+n} \mathbf{w}] + \lambda(\mathbf{w}^H \mathbf{a} - 1), \quad \lambda \text{ 是一个实数标量。}$$

对 \mathbf{w}^* 求导，则 $\mathbf{g}_w = \mathbf{R}_{i+n} \mathbf{w} + \lambda \mathbf{a}$

类似LCMV，代入 $\mathbf{a}^H \mathbf{w} = 1$

$$-\lambda \mathbf{a}^H \mathbf{R}_{i+n}^{-1} \mathbf{a} = 1$$

$$\mathbf{w} = \frac{\mathbf{R}_{i+n}^{-1} \mathbf{a}}{\mathbf{a}^H \mathbf{R}_{i+n}^{-1} \mathbf{a}}$$